《基于早期预警信号的 DDoS 攻击预测智能系统》

An Intelligent System for DDoS Attack Prediction Based on Early Warning Signals

小组成员：蒋凯 万李裔 陈浙豫 程新越 任昶宇

目录

01 研究背景与问题

02 系统架构与运行流程

03 EWS 特征与分类方法

04 实验设计与结果分析

05 结果讨论、局限与结论

研究背景与问题

An Intelligent System for DDoS Attack Prediction Based on Early Warning Signals

COOPRED DDoS 论文研讨

研究问题

能否在 DDoS 攻击正式启动前，从准备活动留下的流量变化中识别预警信号？ 重点不在识别已经造成损害的流量，而在于识别其准备阶段可能出现的征兆。

核心思路

多个监测 Agent 处理流量，提取早期预警特征，再由情报中心联合分类并通知管理员。 EWS 工程也可作为独立步骤使用，不必与系统的全部组件绑定。

报告结构

研究背景 → 系统架构 → EWS 与分类方法 → 实验结果 → 局限与结论 以下按研究问题、实现机制、实验依据与适用边界逐步展开。

研究动机：为管理员争取响应时间

现有困难

DDoS 攻击会快速增加网络与服务资源的消耗，影响正常用户；检测与缓解过程又需要时间。 作者强调两种时间限制：攻击可迅速达到较大流量，防御机制又需要完成分析和处置。

研究切入点

攻击准备活动可能在流量中留下征兆。若能在攻击启动前识别这些征兆，就可能增加响应窗口。 与只等待服务退化相比，分析准备活动希望将风险通知前移。

研究目标

利用准备阶段的早期预警信号预测可能的攻击，并向管理员通知风险；实验重点是预警，而非证明自动阻断效果。 系统输出的是可能攻击的预警；能否成功缓解还取决于后续响应。

概念边界：预测、检测与缓解

任务	关注时间与目标	与该论文的关系
预测	攻击启动前，识别准备阶段信号	该论文的核心任务
检测	识别已经出现的攻击	作者用来说明现有响应时间限制
缓解	采取措施减轻攻击影响	预警后的可能处置，不是该论文实验核心

理解结果时，应将“预测发生的时间”“攻击启动时间”和“攻击峰值时间”区分开。

为什么攻击准备阶段值得分析

- 僵尸网络准备活动可能影响网络流量特征。 CTU-13 中，感染后监测到的发送包数增加，反映僵尸设备开始交换数据包。

- 作者将攻击发生前的变化转化为早期预警信号。每个监测点独立计算特征，再与其他位置的信号一起分类。

- 感染、预警、攻击启动与峰值并不同时发生。实验 1 中， 527 秒感染、 576 秒正确预警、 778 秒攻击启动。

- 正常流量也会产生明显波动。例如 336 秒的峰度峰值在感染之前，因此被标为正常，不能把所有峰值当成预警。

研究问题与主要贡献

信号层面

构建早期预警信号（ EWS ）工程，将网络流量属性转化为用于攻击预测的特征。 信号从时间序列计算得到，不要求预先掌握特定攻击签名或依赖 IDS 告警。

系统层面

设计 COOPRED DDoS ，将分布式流量处理与集中式协同分类结合起来。 Agent 处理分散流量，中心保留信号间的关系，避免分布式处理后信息被割裂。

评估层面

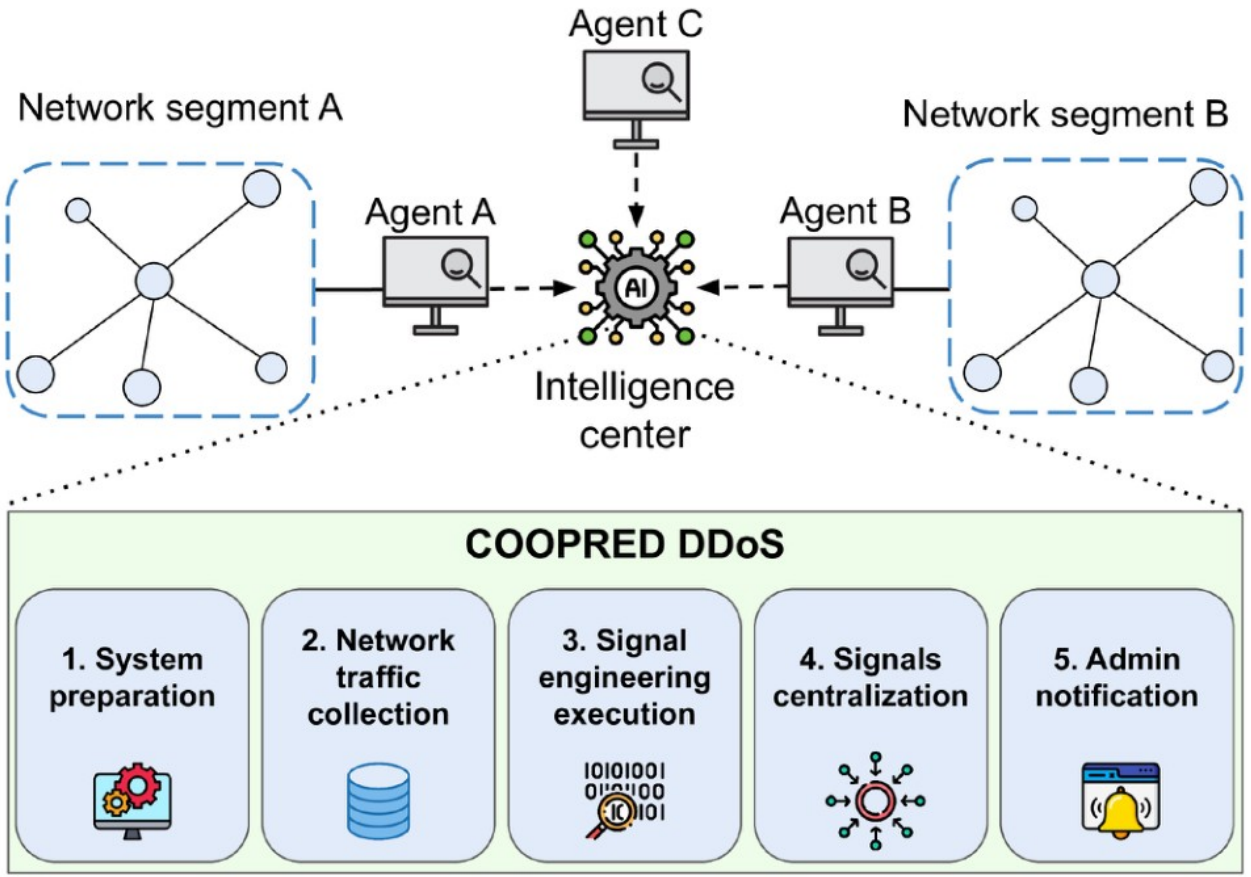
在两组公开数据上开展四组实验，比较准确率、预警精确率、预警召回率和预测提前量。 实验不仅比较分类对错，还将预警时刻与攻击启动时刻对应起来。

已有预测方法的依赖与研究切入点

对外部数据与 IDS 告警的依赖	作者指出，部分方法分析互联网数据或 IDS 告警。如果这些来源没有体现攻击征兆，系统就可能无法作出有效预测。
对 C&C 通信特征的依赖	部分早期僵尸网络检测方法需要了解命令与控制通信方式；攻击者改变通信行为时，既有方法可能受到影响。
COOPRED DDoS 的切入点	从网络流量中计算 EWS ，将分布式处理与协同分析结合起来，减少对特定攻击签名和外部告警的依赖。

系统架构与运行流程

系统架构： Agent 与情报中心



Agent

各 Agent 在所属网段采集流量，将数值型流量属性组织为时间序列，并计算早期预警信号（EWS）。

情报中心

汇集各 Agent 在同一采集周期产生的 EWS，完成缺失处理、尺度变换与机器学习分类。

管理员

情报中心识别出可能的攻击后，向网络管理员发送预警通知，默认通知方式为电子邮件。

分布式处理与协同机制

多网段分布式采集

Agent 分布在不同网段，分别采集和处理本地网络流量。 Agent 数量依据硬件可用性、网络拓扑和网络规模配置；网段流量镜像到对应的 Agent 进行分析。

本地信号计算

每个 Agent 为各项流量属性维护时间序列，并在每个采集周期执行 EWS 工程，将流量属性转换为反映分布变化的早期预警信号。

同周期信号协同

各 Agent 将 EWS 发送至情报中心。中心联合同一采集周期内各 Agent 的信号，保留分布式处理数据之间的关联，并利用机器学习识别可能的 DDoS 攻击。

流量输入与信号上报

数值型流量属性

系统接收数值型流量属性，包括发送包数、包长比例、接收包时间间隔比例及相关方差等，用户可配置采集属性。

实验输入配置

四组实验均以每秒发送包数作为流量输入。各 Agent 按采集周期记录包数，并在本地时间序列上计算 EWS 。

信号上报内容

每个采集周期结束后， Agent 向情报中心发送 EWS 、本地身份标识，以及该周期的开始和结束时间。

Description
Number of packets sent
Ratio of packets with flag RESET in a session
Ratio of the sent packets having the size of 100-199 bytes
Ratio of the sent packets having the size of bytes
Ratio of packets with flag S in a session
Variance of sent packets
Maximum interval time in received packets
Variance of interval time of received packets
Ratio of the sent packets having the size of 500-599 bytes
Variance of packet size of the received packets

系统可用的网络流量属性如表所示；每个 Agent 从所监测网段提取配置的属性。

采集周期、时间同步与等待策略

- 配置采集周期：默认值为 1 秒，用户可按需求调整。周期长度决定各 Agent 开始、结束数据采集和 EWS 计算的时间范围。

- 同步采集定义： Agent 在采集前同步流量属性、采集周期及当前时间，使情报中心能够按采集时刻对应不同网段的信号。

- 周期性上报： Agent 在每个采集周期执行 EWS 工程，将计算结果连同本地标识、周期起止时间发送至情报中心。

- 等待与超时：情报中心默认等待三个采集周期以接收全部 Agent 的信号；超时仍未发送信号的 Agent 被标记为离线。等待时限可配置。

中心处理流程：从信号汇总到通知

1. 汇总与预处理

汇总同一采集周期的信号，删除含缺失输入的信号，或使用中位数、均值、常数填补缺失项。通过标准化或 Min-Max 缩放统一数据尺度，默认使用 Min-Max 。

2. 机器学习分类

联合各 Agent 的 EWS 作为分类输入，识别信号分布中可能先于 DDoS 攻击出现的变化。情报中心支持浅层与深层机器学习方法，默认分类器为 AdaBoost 。

3. 管理员预警通知

当分类输出对应可能的攻击时，系统通知网络管理员。默认通过电子邮件发送；通知形式还包括短信、推送，以及可作为防火墙或告警系统输入的 JSON 消息。

情报中心的处理逻辑

Algorithm 1 Intelligence Center Pseudocode

```
while True do
    cycle_time, waiting_time, ml_model ← get_definitions()
    wait(waiting_time)
    signal, complete_cycle ← get_signals()
    if not complete_cycle then
        wait(cycle_time * waiting_time)
        signal, complete_cycle ← get_signals()
        if not complete_cycle then
            set_agents_offline(signals)
        end if
    end if
    signals ← process_missing_signals(signals)
    signals ← rescale_signals(signals)
    has_attack_warning ← ml_model.predict(signals)
    if has_attack_warning then
        notify_administrators()
    end if
    set_signals_as_processed(signals)
end while
```

等待与完整性检查

读取采集周期、等待时间和模型配置，接收各 Agent 的信号；信号不完整时再次等待，仍不完整则将相应 Agent 标记为离线。

预处理与分类

依次处理缺失信号、缩放数据，再调用机器学习模型进行预测，判断当前周期是否出现攻击预警。

通知与状态更新

预测结果为攻击预警时通知管理员；将信号标记为已处理，随后继续执行下一轮接收与分类。

EWS 特征与分类方法

EWS 与临界转变

概念基础

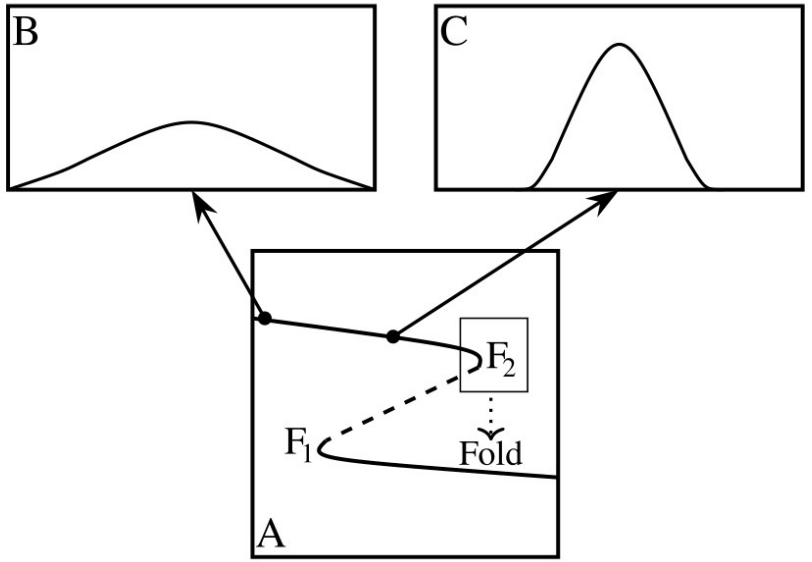
EWS 用于描述临界转变前的统计征兆。论文把可能的 DDoS 攻击与临界转变联系起来。

图中含义

A 表示状态转变过程； B 、 C 示意远离或接近临界转变时，数据分布可能呈现的不同形态。

应用到网络流量

作者将连续观测组织成时间序列，再计算统计与频域特征；显著变化仍需分类模型进一步判断。



这是论文引用的概念示意图，不是该论文的 DDoS 实验结果。

特征处理链：包数 → EWS → 周期分类

Agent 端	统计所属范围内设备每秒发送的数据包数量，形成流量时间序列，再按采集周期计算 EWS 特征。 时间序列按观测顺序排列； Agent 在本地完成特征计算后再发送信号。
中心端	将各 Agent 同一周期的特征联合起来，处理缺失值，并进行尺度变换；默认采用 Min-Max 缩放。 每条信号附有 Agent 标识与周期起止时间，使联合分析能对应同一时刻。
分类输出	每个周期输出“正常秒”或“攻击预警秒”。评估中的正类是预警秒，而不是一次完整攻击事件。 因此，后续精确率和召回率是在这些周期标签上计算，不能直接转换成事件级效果。

统计与频域特征：分别观察哪些变化

特征	作用与解释
偏度（ Skewness ）	描述分布不对称性，帮助观察分布形态的变化。
峰度（ Kurtosis ）	关注尾部和极端观测；不能仅用曲线的峰高解释。
Smax	最大功率谱；先估计功率谱，再从最近观测中寻找最大值，用于观察重复模式与相关性。
Snull 、 Sfold 、 Shopf	Smax 的变体； Snull 较平坦时可能远离临界转变， Sfold 与 Shopf 接近转变时增大。

作者选择偏度、峰度与 Smax ，是因为它们可能出现极端变化；频谱变体进一步补充转变类型信息。所有特征仍需联合分类。

信号工程：时间序列维护与通信内容

时间序列按属性维护

每个 Agent 为所选网络属性维护一条时间序列，按观测顺序持续加入采集结果，并在每个采集周期计算 EWS 。

历史长度与采集周期不同

序列达到用户设定的最大长度时，移除最旧观测。最大长度依设备资源设置，不等同于实验采用的 1 秒采集周期。

传输的是处理后的信号

Agent 向中心发送 EWS 、本地标识、周期起止时间，而不是将所有原始属性直接集中；中心据此联合同周期特征。

分类模型： AdaBoost 与 MLP

项目	AdaBoost	MLP
共同输入	各 Agent 同周期的 EWS 特征	各 Agent 同周期的 EWS 特征
分类目标	正常秒 / 攻击预警秒	正常秒 / 攻击预警秒
实验配置	5 个估计器	3 个隐藏层，神经元数为 33 、 17 、 11
其他设置	以决策树为估计器	使用 L-BFGS 优化

比较两个模型时，不仅要看分类质量，还要看哪一个能够更早识别预警信号。

联合分类前的缺失处理与尺度变换

环节	方法与作用
缺失项处理	删除缺失信号，或以中位数、均值、常数等填补；论文实验使用常数− 1 。
标准化	(x − 均值) / 标准差，用于处理不同量纲与取值尺度。
Min-Max 缩放	映射到设定范围；若目标为 [0,1] ，可写为 (x − 最小值) / (最大值 − 最小值) 。

Min-Max 是系统默认策略。完成预处理后，中心将各 Agent 同周期的 EWS 联合输入模型，输出正常秒或攻击预警秒。

实验设计与结果分析

实验设置与评价指标

数据集	训练 / 测试场景	时长（训练 / 测试）	模型实验编号
CTU-13	Scenario 10 / Scenario 11	8803 秒 / 972 秒	AdaBoost： 1； MLP： 3
CICDDoS2019	UDP Attack / UDP-Lag Attack	1277 秒 / 1260 秒	AdaBoost： 2； MLP： 4

共同设置

4 个 Agent；每秒发送包数； 1 秒采集周期。缺失值以− 1 填补并作 Min-Max 缩放。

运行环境： i5 、 240GB 固态硬盘、 8GB 内存。

指标口径：正类为预警秒

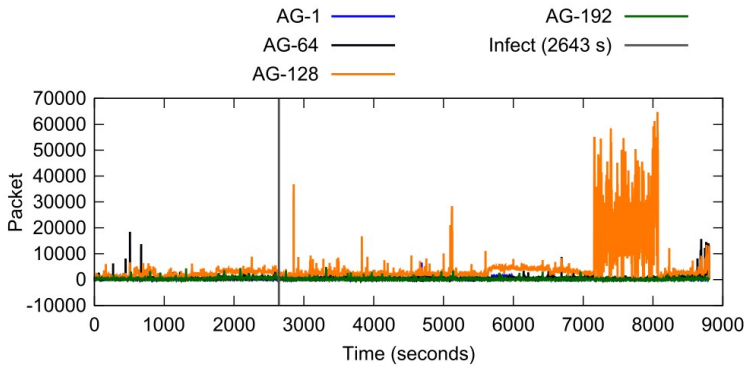
准确率： (TP + TN) / N

预警精确率： TP / (TP + FP)

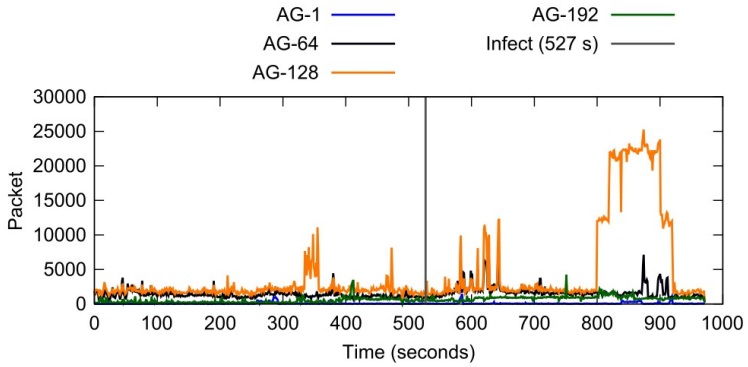
预警召回率： TP / (TP + FN)

CTU-13： 原始流量与 EWS 结果

每秒发送包数（训练 / 测试）

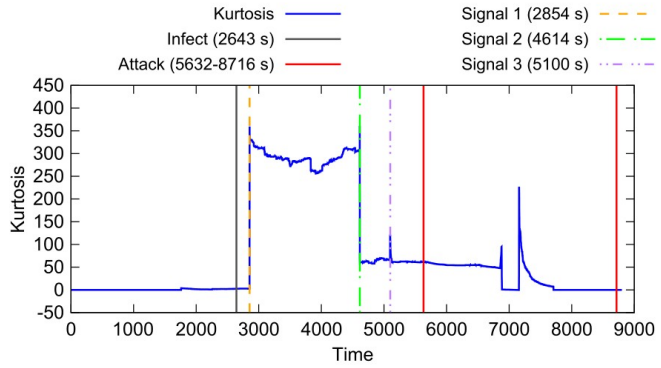


(a) Packet count per second in training.

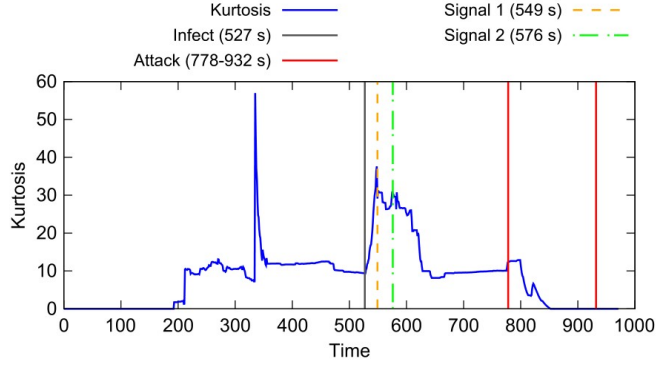


(b) Packet count per second in the test.

峰度变化（训练 / 测试）



(a) Kurtosis per second in training.

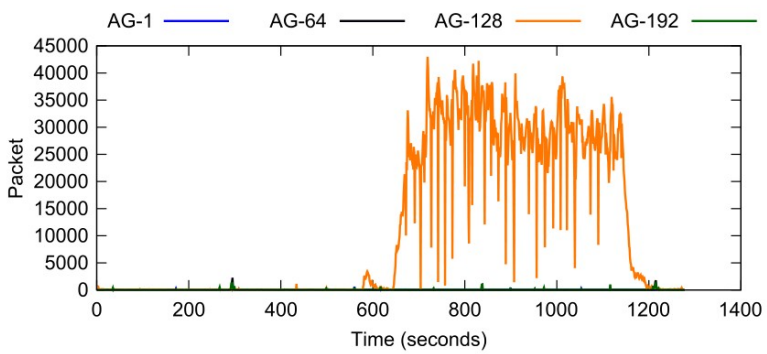


(b) Kurtosis per second in the test.

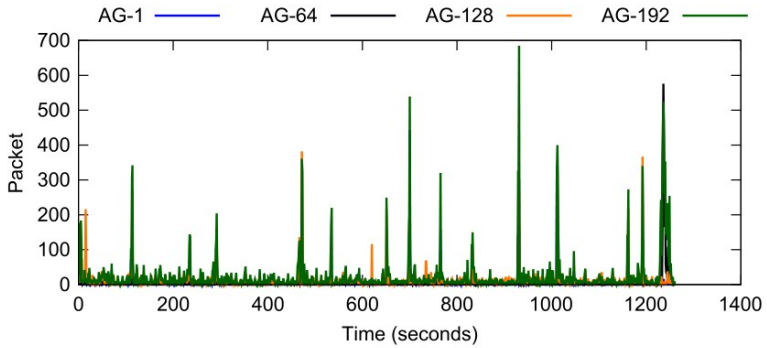
测试场景： 527 秒开始感染； 336 秒峰值标为正常； 549 、 576 秒标为预警；攻击于 778 秒启动。

CICDDoS2019： 原始流量与 EWS 结果

每秒发送包数（训练 / 测试）

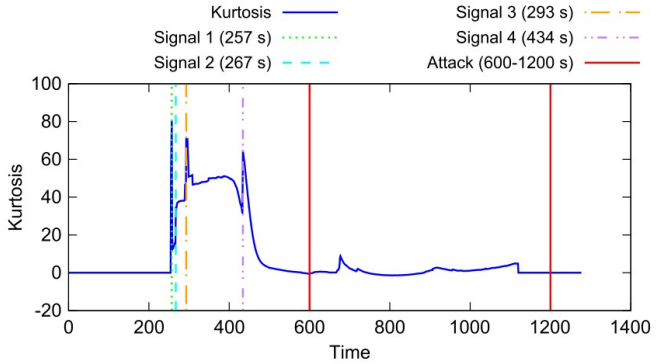


(a) Packet count per second in training.

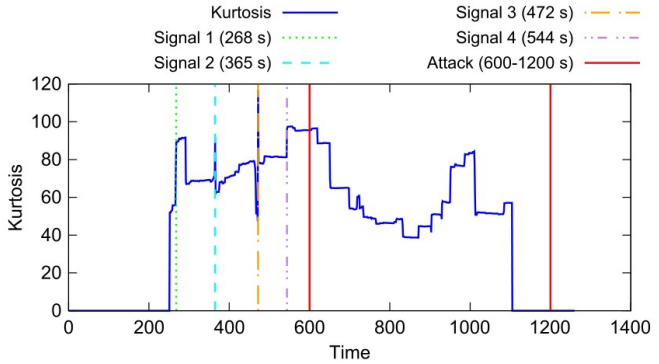


(b) Packet count per second in the test.

峰度变化（训练 / 测试）



(a) Kurtosis per second in training.



(b) Kurtosis per second in the test.

测试场景： 268 、 365 、 472 、 544 秒标为预警。 472 秒峰度由 47.2 增至 116.7 ，仍需模型识别这些标签。

四组实验结果：分类质量与提前量

实验	数据集	模型	准确率	预警精确率	预警召回率	提前量
1	CTU-13	AdaBoost	99.69%	33.33%	50%	3 分 22 秒
2	CICDDoS2019	AdaBoost	99.76%	100%	25%	2 分 08 秒
3	CTU-13	MLP	98.87%	9.09%	50%	3 分 49 秒
4	CICDDoS2019	MLP	99.60%	33.33%	25%	3 分 55 秒

同一数据集上， AdaBoost 分类更准确， MLP 更早预警，但误报更多。

表中提前量均相对于攻击启动；精确率与召回率统计的是预警秒。

原始混淆矩阵与误报代价

实验 1： CTU-13 / AdaBoost

Confusion matrix		Real class	
		Attack warning	normal second
Hypothetical class	Attack warning	1	2
	Normal second	1	968

实验 2： CICDDoS2019 / AdaBoost

Confusion matrix		Real class	
		Attack warning	normal second
Hypothetical class	Attack warning	1	0
	Normal second	3	1256

实验 3： CTU-13 / MLP

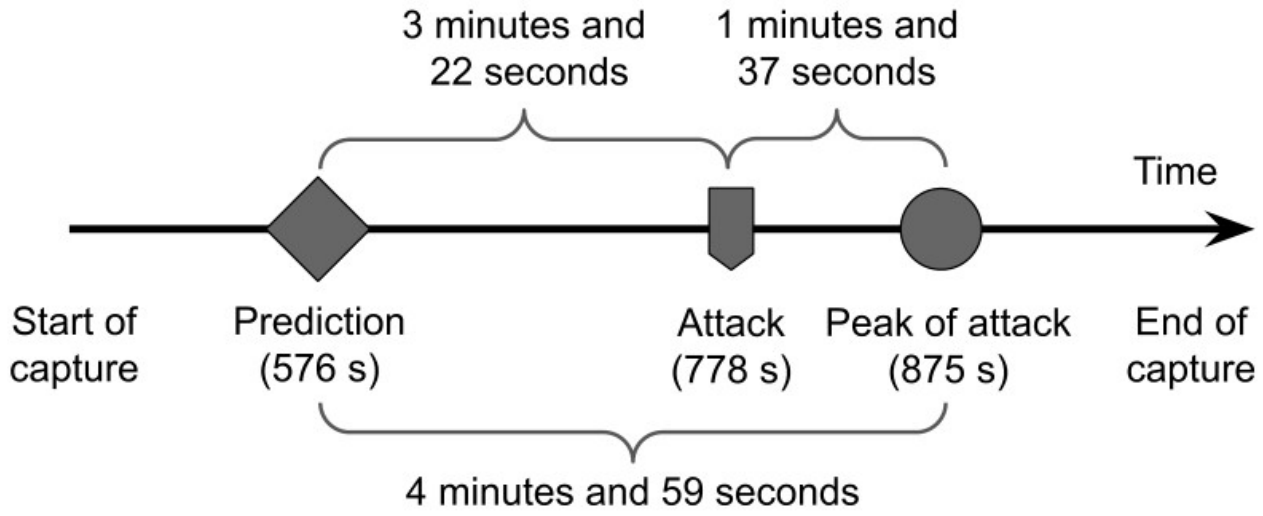
Confusion matrix		Real class	
		Attack warning	normal second
Hypothetical class	Attack warning	1	10
	Normal second	1	960

实验 4： CICDDoS2019 / MLP

Confusion matrix		Real class	
		Attack warning	normal second
Hypothetical class	Attack warning	1	2
	Normal second	3	1254

CTU-13： MLP 早 27 秒，误报由 2 增至 10 秒； CICDDoS2019： 早 1 分 47 秒，误报由 0 增至 2 秒。原表按列为真实类别、按行为预测类别。

提前量示例：攻击启动与峰值的时间口径



事件	时刻	相对正确预警的时间差
正确预警	576 秒	—
攻击启动	778 秒	202 秒，即 3 分 22 秒
攻击峰值	875 秒	299 秒，即 4 分 59 秒

结果讨论、局限与结论

高准确率为什么不足以证明预测有效

类别极不平衡

CTU-13 测试集共有 972 秒，其中只有 2 秒被标为攻击预警。 在对应训练集中， 8803 秒仅有 3 秒预警标签；正类在训练与测试中都十分稀少。

全部判断正常的基线

即使一个预警也没有找到，仍可正确分类 970 秒，准确率约为 970 / 972 = 99.79% 。 这种基线虽然准确率高，却没有识别任何攻击准备信号，因而无法完成预警任务。

对实际结果的理解

四组实验的预警召回率为 25% 或 50% 。应同时考察精确率、召回率、预警数量与提前量。 例如实验 2 有 100% 的预警精确率，但只识别 4 个预警标签中的 1 个，召回率为 25% 。

预警标签如何构造：理解模型在学习什么

测试场景	正常或感染信息	预警标签时刻
CTU-13	336 秒峰值为正常； 527 秒开始感染	549 秒、 576 秒
CICDDoS2019	未明确给出感染起点；起始已有僵尸网络流量	268 秒、 365 秒、 472 秒、 544 秒

- 作者结合 EWS 极值、感染信息和攻击时刻标注预警秒。
- 模型评估对象是这些预警秒标签，不是攻击源定位或攻击强度预测。
- CTU-13 训练集有 8803 秒，但只有 3 秒预警标签，进一步体现类别不平衡。

部署局限与后续方向

情报中心的单点故障

尽管 Agent 分散处理流量，信号分析仍集中在中心；中心失效可能影响预警。 作者计划研究由 Agent 执行分布式预测，使中心不可用时仍可能向管理员告警。

真实环境中的标签依赖

监督学习需要标注数据，而真实部署中获得合适标签可能具有挑战。 当前模型需要基于预警标签训练，作者提出用无监督学习降低对标注的依赖。

后续研究方向

探索 Agent 分布式预测，以及使用无监督学习减少标签依赖。上述方向属于未来研究，并非已验证成果。 论文没有在这些改进之后重新报告实验结果，应将已完成的验证与研究计划分开。

评估局限与后续研究计划

输入属性有限

当前实验只采用每秒发送包数，作者将所使用的属性列为评估的一项局限。 虽然系统支持多类数值型属性，但该论文结果并未覆盖全部可选输入。

进一步研究特征

后续计划测试其他属性，并评估哪些属性更适合用于 EWS 工程。 选择何种属性会影响对准备活动的描述；最佳属性组合仍属于作者的后续问题。

进一步评估系统

研究分布式方案对精确率、预测时间和网络数据处理的影响；这些工作未在该论文完成。 作者指出这些未来工作并不简单，该论文的主要目标仍是验证 EWS 工程及协同系统。

与 ANTE 的对比及适用边界

System	Prediction time	Distributed processing	Different ML	Details
COOPRED DDoS (Adaboost)	3 min 22 s	✓	✓	✗
COOPRED DDoS (MLP)	**3 min 49 s**	✓	✓	✗
ANTE [44]	0 min 30 s	✗	✓	✓

在论文列出的 CTU-13 场景比较中：

ANTE： 提前 30 秒； COOPRED DDoS / AdaBoost： 提前 3 分 22 秒； MLP： 提前 3 分 49 秒。

对比维度

提前量、是否分布处理、能否采用不同模型，以及处理数据的详细程度。

任务并不完全相同

作者指出 ANTE 面向僵尸网络识别，COOPRED DDoS 面向可能的 DDoS 攻击通知。

适用范围

对比基于特定 CTU-13 场景。两种系统的任务和数据处理方式不同，结果不宜直接推广到所有网络与攻击。

结论：方法、证据与适用边界

方法

COOPRED DDoS 将分布式流量处理、 EWS 工程、协同分析和机器学习结合起来，识别攻击准备信号。 在方法链中，本地特征计算分摊处理工作，中心联合信号，分类器自动判断预警标签。

证据

两组数据、四组实验均发现了攻击启动前的正确预警； MLP 获得更长提前量，同时产生更多误报。 CTU-13 中 MLP 提前 3 分 49 秒， CICDDoS2019 中提前 3 分 55 秒；这些提前量均相对于启动。

边界与目标

需要同时理解提前量、预警精确率与召回率。研究目标是为管理员增加响应时间，后续仍需推进作者提出的改进与验证。 这项研究展示了准备阶段信号的利用方式，但不能只凭高准确率忽略误报与漏报。

感谢聆听

敬请老师批评指正